

ECONOMETRIE

Curs 6

Ipoteze clasice ale modelului de regresie (II)

Ipoteze clasice ale modelului de regresie

- ▶ Datele sunt corecte, modelul este corect specificat.
 - ▶ I1) Forma funcțională este liniară.
 - ▶ I2) Necolinaritatea variabilelor explicative.
 - ▶ I3) Erorile aleatoare au media zero.
 - ▶ I4) Necorelarea dintre regresori și erori.
 - ▶ I5) Homoscedasticitatea erorilor aleatoare.
 - ▶ I6) Erorile aleatoare nu sunt autocorelate.
 - ▶ I7) Erorile aleatoare au o distribuție normală.
- Dacă una (sau mai multe) din aceste ipoteze nu este îndeplinită, nu este recomandat să se folosească MCMMP pentru estimarea parametrilor.

Erorile aleatoare au media zero

$$E(\varepsilon_i | x_i) = E(\varepsilon_i) = 0, i = 1, 2, \dots, n$$

- ▶ Eroarea aleatoare este văzută ca suma efectelor individuale datorate unor factori aleatori.
- ▶ Înseamnă că, **în medie**, factorii neînregistrați nu au efect asupra mediei variabilei Y .
- ▶ Valorile pozitive și negative ale variabilei reziduale se anulează între ele.
- ▶ Dacă în cadrul modelului au fost incluse acele variabile ce influențează în mod real valoarea lui Y , atunci ecartul sau abaterea dintre cele două tipuri de valori, reale și estimate, tinde spre zero, iar în medie acesta este zero.

Necorelarea dintre regresori și erori

$$\text{cov}(\varepsilon_i, x_i) = 0 \quad \text{pentru orice } i \text{ și } j.$$

- ▶ Această proprietate poate fi exprimată într-o formă echivalentă:

$$E(\varepsilon_i x_i) = 0 \quad \text{pentru orice } i \text{ și } j.$$

- ▶ Erorile aleatoare sunt independente de variabilele explicative. Variabila X nu este stochastică, adică valorile sunt fixate în selecții repetate. Înseamnă că se regăsesc aceleași valori dacă se face o nouă selecție.
- ▶ În plus, se presupune că factorul X prezintă variabilitate și deci, poate fi evidențiat rolul acestui factor.

Normalitatea erorilor

- ▶ Erorile aleatoare sunt presupuse a fi normal distribuite, pentru orice i .

$$\varepsilon_i \sim N(0, \sigma^2) \quad (\forall) i = \overline{1, n}$$

- ▶ Teorema Limită Centrală: Dacă există un număr mare de variabile aleatoare independente și identic distribuite (*iid*), atunci distribuția sumei lor tinde să fie o distribuție normală, atunci când numărul variabilelor crește indefinit.
- ▶ În practică, atunci când mărimea eșantionului este suficient de mare, testarea normalității nu este necesară deoarece teorema limitei centrale asigură distribuirea aproximativ normală a erorii.

Normalitatea erorilor

- ▶ Stă la baza **inferenței statistice** (cum ar fi testele de ipoteze și intervalele de încredere) pentru coeficienții de regresie.
- ▶ Atunci când erorile sunt distribuite normal, estimatorii obținuți prin metoda celor mai mici pătrate sunt **nedeplasați** (neafectați de eroare sistematică) și au **varianța minimă** dintre toți estimatorii liniari nedeplasați (conform teoremei Gauss–Markov).
- ▶ În practică, normalitatea erorilor justifică utilizarea testelor t și F în analiza de regresie, permițând luarea unor decizii riguroase și fiabile pe baza datelor din eșantion.

Consecințele non-normalității



- ▶ **Pentru eșantioane mari** – Teorema limită centrală garantează că distribuția mediei (și a altor statistici) este aproximativ normală, chiar dacă datele inițiale nu respectă perfect distribuția normală. Inferențele realizate sunt valide în majoritatea cazurilor practice atunci când dimensiunea eșantionului este mare.
- ▶ **Pentru eșantioane mici** – Dacă erorile nu urmează o distribuție normală, acest lucru poate conduce la inferențe eronate: intervalele de încredere și valorile p obținute în urma regresiei pot fi inexacte, iar testele statistice devin mai puțin fiabile.
- ▶ Este deosebit de importantă verificarea normalității în cazul eșantioanelor mici, deoarece prezența valorilor aberante sau a datelor asimetrice pot influența rezultatele modelului.

Normalitatea erorilor – analiză grafică

- ▶ Analiza grafică poate fi utilizată pentru a verifica dacă reziduurile urmează o distribuție normală, condiție necesară pentru validitatea multor teste statistice inferențiale.
- ▶ Graficele utilizate frecvent includ:
 - **Histograma reziduurilor**
 - **Suprapunerea curbei normale teoretice pe histograma**
 - **Graficul Q–Q al reziduurilor**
- ▶ Aceste grafice oferă un mod rapid și eficient de a evalua ipoteza normalității în cadrul diagnosticării unui model de regresie.


Normalitatea erorilor – analiză grafică

- ▶ **Histograma reziduurilor** – permite observarea distribuției reziduurilor și identificarea eventualelor asimetrii sau valori aberante (outlieri).



Normalitatea erorilor – analiză grafică

- ▶ Graficul Q-Q al reziduurilor (Normal Probability Plot) – compară distribuția reziduurilor cu o distribuție normală teoretică; dacă punctele se aliniază de-a lungul unei drepte, acest lucru indică o bună conformitate cu ipoteza normalității.



Teste pentru normalitate

- ▶ **Testul Jarque–Bera** – evaluează dacă reziduurile prezintă simetria (*skewness*) și gradul de aplatizare (*kurtosis*) caracteristice unei distribuții normale.
- ▶ **Testul Shapiro–Wilk** – verifică dacă reziduurile provin dintr-o populație cu distribuție normală; este deosebit de eficient pentru eșantioane mici.
- ▶ **Testul Kolmogorov–Smirnov** – compară distribuția empirică a datelor cu o distribuție normală teoretică, pentru a detecta diferențe semnificative între cele două.
- ▶ Respingerea ipotezei nule în oricare dintre aceste teste constituie o dovadă a non-normalității reziduurilor.

Normalitatea erorilor

Testul Jarque-Bera

- ▶ Cele două ipoteze sunt:
 - H_0 – erorile sunt normal distribuite
 - H_1 – erorile nu sunt normal distribuite
- ▶ Valoarea **statisticii JB** se calculează cu formula:

$$JB = n \left[\frac{(C_{as})^2}{6} + \frac{(C_{bolt} - 3)^2}{24} \right]$$

unde

- ▶ C_{as} este coeficientul de asimetrie al variabilei reziduale
- ▶ C_{bolt} este coeficientul de boltire Pearson al variabilei reziduale

Asimetria și boltirea

– Coeficienții lui Pearson –

$$C_{as} = \beta_1 = \frac{\mu_3^2}{\mu_2^3}$$

unde

$$\mu_2 = \sigma^2 = \frac{\sum (\varepsilon_i - \bar{\varepsilon})^2}{n}$$

(momentul centrat de ordin 2)

$$\mu_3 = \frac{\sum (\varepsilon_i - \bar{\varepsilon})^3}{n}$$

(momentul centrat de ordin 3)

$$C_{bolt} = \beta_2 = \frac{\mu_4}{\mu_2^2}$$

unde:

$$\mu_4 = \frac{\sum (\varepsilon_i - \bar{\varepsilon})^4}{n}$$

(momentul centrat de ordinul 4)

Normalitatea erorilor

Testul Jarque–Bera

- ▶ Valoarea calculată a testului JB urmează o repartiție χ^2 cu 2 grade de libertate.

- ▶ **Decizia:**

Dacă valoarea calculate a testului JB este inferioară valorii tabelare $\chi^2_{\alpha,2}$ vom accepta ipoteza H_0 (erorile sunt normal distribuite).

Normalitatea erorilor – Robustețe

- ▶ *Atunci când distribuția erorilor se dovedeste a nu respecta ipoteza de normalitate:*
- ▶ **Eșantioane mari** – Testele t și inferențele rezultate din regresie rămân, în general, fiabile, chiar și atunci când datele nu respectă perfect o distribuție normală.
- ▶ **Tehnica bootstrap**
 - oferă o alternativă flexibilă la testele statistice tradiționale.
 - nu impune ipoteza normalității și permite obținerea unor intervale de încredere precise, fiind deosebit de utilă în cazul eșantioanelor mici sau al datelor care se abat puternic de la normalitate.


Corectarea lipsei de normalitate

- ▶ **Transformarea variabilelor (logaritm, rădăcină pătrată)** – Aplicarea unor transformări matematice poate reduce asimetria și poate face datele mai compatibile cu ipoteza normalității, îmbunătățind astfel modelul de regresie.
- ▶ **Eliminarea valorilor aberante** – Identificarea și eliminarea valorilor extreme limitează influența lor disproporționată și permite reziduurilor să urmeze mai bine o distribuție normală.
- ▶ **Utilizarea metodelor de regresie robuste** – Tehnicile robuste reduc sensibilitatea la non-normalitate și la valori extreme, oferind rezultate mai fiabile atunci când metodele clasice nu sunt adecvate.


Homoscedasticitatea erorilor aleatoare

- ▶ Erorile aleatoare sunt homoscedastice:
→ varianță constantă

$$Var(\varepsilon_i) = E(\varepsilon_i - E(\varepsilon_i))^2 = \sigma^2, i = 1, 2, \dots, n$$



a) Cazul homoscedasticității



b) Cazul heteroscedasticității

Cauze ale apariției heteroscedasticității erorilor

- Modelul de regresie nu este corect specificat (modelul nu include variabilele explicative esențiale sau forma sa nu este cea potrivită).
 - Neomogenitatea datelor.
 - Erorile de măsurare.
 - Seriile de date sunt constituite din valori medii și nu din valori individuale.
 - Asupra seriilor de date nu au fost aplicate transformări corecte.
- 

Consecințe ale prezenței heteroscedasticității erorilor

1. Estimatorii obținuți prin MCMMP sunt în continuare liniari și nedeplasați, dar **nu mai sunt eficienți**, adică nu mai au varianță minimă.
 2. **Estimatorul varianței erorilor aleatoare** nu mai este nedeplasat ci **este deplasat**.
 3. Estimatorii varianțelor coeficienților modelului sunt deplasați.
 4. Erorile standard ale coeficienților modelului sunt estimate greșit; **testele t și F sunt incorecte**.
 5. **Intervalele de încredere** și testele de ipoteze bazate pe distribuțiile t și F nu sunt sigure, nu sunt de încredere.
- 

Detectarea heteroscedasticității

– Testul White –

$H_0 : \sigma_i^2 = \sigma^2 = \text{constant}$ pentru toți indicii $i = \overline{1, n}$ (există homoscedasticitate)

$H_1 : \sigma_i^2 \neq \sigma^2$ pentru cel puțin un indice (există heteroscedasticitate)

Mai întâi se estimează modelul prin MCMMP și se rețin reziduurile. Testul White implică regresia pătratelor reziduurilor, e_i^2 , în funcție de toate variabilele explicative, de pătratele variabilelor explicative și de produsele lor încrucișate.

Considerăm modelul cu 2 variabile explicative:

$$y_i = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \varepsilon_i$$

Pas1. Estimăm modelul inițial de regresie prin MCMMP și reținem reziduurile e_i .

Pas2. Construim o regresie auxiliară:

$$e_i^2 = a_0 + a_1 x_{i1} + a_2 x_{i2} + a_3 x_{i1}^2 + a_4 x_{i2}^2 + a_5 x_{i1} x_{i2} + \eta_i$$

(În modelul cu 3 variabile explicative, regresia auxiliară va conține următoarele variabile exogene:

$$x_1, x_2, x_3, x_1^2, x_2^2, x_3^2, x_1 x_2, x_1 x_3, x_2 x_3).$$

Detectarea heteroscedasticității

– Testul White –

Pas3. Obținem coeficientul de determinație multiplă din regresia auxiliară, notat R_a^2 .

Verificăm validitatea regresiei auxiliare (semnificația parametrilor modelului auxiliar).

$H_0 : a_1 = a_2 = a_3 = a_4 = a_5 = 0$ (există homoscedasticitate)

$H_1 : (\exists) a_i \neq 0$ (există heteroscedasticitate)

Sub ipoteza nulă, că nu există heteroscedasticitate, White a arătat că statistica $W = nR_a^2$ urmează asimptotic o distribuție χ^2 cu gradele de libertate date de numărul de regresori din ecuația auxiliară.

$W = nR_a^2 \sim \chi_{df}^2$. În modelul considerat avem $df=5$.

Pas4. Dacă valoarea calculată a statisticii W , adică $W_{calculat} = nR_a^2 > \chi_{critic,\alpha}^2$, sau dacă p-value este mai mică decât nivelul de semnificație ales, respingem H_0 și acceptăm $H_1 \Rightarrow$ **erorile aleatoare sunt heteroscedastice.**

Detectarea heteroscedasticității erorilor


Alte metode de detectare a heteroscedasticității erorilor:

- ❑ Metoda grafica
 - ❑ Testul Goldfeld-Quandt
 - ❑ Testul Park
 - ❑ Testul Glejser
 - ❑ Testul Breusch – Pagan – Godfrey
- 


Detectarea heteroscedasticității erorilor

– Metoda grafică –

– Se reprezintă grafic reziduurile regresiei (obținute în urma estimării modelului prin MCMMP) în raport cu fiecare variabilă explicativă X .



a) Modelul homoscedastic al erorilor



b) Modelul heteroscedastic al erorilor

- ▶ Se consideră că erorile aleatoare prezintă heteroscedasticitate, dacă se obține o structură „în trompetă”

Corectarea heteroscedasticității

- Redefinirea variabilelor
- Respecificarea modelului
- Transformarea variabilelor (logaritmare)
- Metoda celor mai mici pătrate ponderată
- Estimarea parametrilor folosind erorile standard robuste ale lui White.

Corectarea heteroscedasticității

- **Eliminare heteroscedasticitate:**

- **1. metoda regresiei ponderate:**

- Dacă variația erorii este proporțională cu pătratul variabilei explicative:

$$y_i = a + bx_i + e_i \mid x_i \Rightarrow \frac{y_i}{x_i} = a \frac{1}{x_i} + b + \frac{e_i}{x_i}$$

- Dacă variația erorii este proporțională cu variabila explicativă:

$$y_i = a + bx_i + e_i \mid \sqrt{x_i} \Rightarrow \frac{y_i}{\sqrt{x_i}} = a \frac{1}{\sqrt{x_i}} + b + \frac{e_i}{\sqrt{x_i}}$$

- **2. transformarea logaritmică**

$$\ln y_i = \alpha + \beta \ln X_i + \varepsilon_i$$