

ECONOMETRIE

Curs 11

VARIABLE BINARE

VARIABILELE DEPENDENTE SUNT CALITATIVE

- ▶ Modele cu variabile calitative binare: modele de tip Probit și Logit
- ▶ Modelul de regresie:
 - ▶ $y_i = a_0 + \sum_{j=1}^k a_j x_{ij} + e_i$
- ▶ unde y este o variabila dummy.
- ▶ *Exemplu:* variabila dummy observată indică dacă o persoană are sau nu un loc de muncă, atunci y poate fi definită ca *dorința* sau *abilitatea* de a găsi un loc de muncă.

Modele cu variabile calitative binare: modele de tip Probit și Logit

$$P_i = \text{Prob}(y = 1) = \text{Prob} \left[e_i > - \left(a_0 + \sum_{j=1}^k a_j x_{ij} + e_i \right) \right]$$
$$= 1 - F \left[- \left(a_0 + \sum_{j=1}^k a_j x_{ij} + e_i \right) \right]$$

F este funcția de distribuție cumulată a erorilor.
Dacă F este simetrică, atunci $1 - F(-Z) = F(Z)$ și

$$P_i = F \left(a_0 + \sum_{j=1}^k a_j x_{ij} + e_i \right)$$

Modele cu variabile calitative binare: modele de tip Probit și Logit

- ▶ Modelele probit și logit diferă în ceea ce privește specificarea distribuției erorilor din ecuația de regresie.
- ▶ Dacă distribuția cumulată a erorilor este o funcție logistică rezultă un model de tip *logit*.
- ▶ Dacă distribuția a erorilor urmează o distribuție normală, rezultă un model de tip *probit*.
- ▶ **Modelul probit:**

$$F(Z_i) = \int_{-\infty}^Z \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{t^2}{2}\right) dt$$

- ▶ unde

$$Z_i = a_0 + \sum_{j=1}^k a_j x_{ij} + e_i$$

Modele cu variabile calitative binare: modele de tip Probit și Logit

Modelul Logit

- ▶ Modelul de regresie logistică cu un singur factor explicativ se scrie:

$$P(y = 1|x) = \frac{e^{\alpha + \beta x}}{1 + e^{\alpha + \beta x}}$$

sau

$$\ln \left(\frac{P(y = 1|x)}{1 - P(y = 1|x)} \right) = \alpha + \beta x$$

Modelul Logit

- ▶ Regresia logistică cu mai multe variabile independente

$$\ln \left(\frac{P(y = 1 | x_1, x_2, x_3, \dots, x_k)}{1 - P(y = 1 | x_1, x_2, x_3, \dots, x_k)} \right) = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_k x_k$$

- ▶ Ținând cont de caracterul multiplicativ, modelul logistic poate fi scris utilizând conceptul de *raport de sansa (odds ratio)*:

$$OR_{x_1, x_2, \dots, x_k} = \exp(\beta_0) \cdot \exp(\beta_1 x_1) \cdot \dots \cdot \exp(\beta_k x_k)$$

Modelul Logit

Interpretarea rezultatelor:

- fiecare β_i arată contribuția factorului x_i la explicarea probabilității de producere a evenimentului $y = 1$.
- dacă $\beta_i = 0$, atunci factorul corespunzător nu are niciun efect,
- dacă $\beta_i < 0$ atunci prezența factorului reduce probabilitatea de realizare a evenimentului $y = 1$
- $\beta_i > 0$ mărește această probabilitate.

Modelul Logit

- In practica, se interpreteaza mai des valorile pentru **odds ratio** (raportul de sansa) decat valorile coeficientilor
- Raportul de sansa este o masura a asocierii dintre un factor si un eveniment.
- OR reprezinta sansele ca un eveniment sa se produca avand in vedere un anumit factor, in comparatie cu sansele ca evenimentul sa se produca in absenta acelui factor.

Matricea de confuzie

- ▶ Matricea de confuzie este un tabel utilizat pentru a evalua performanța unui algoritm de clasificare.
- ▶ Este folosită pentru aprecierea predicțiilor corecte și greșite ale modelului.

Matricea de confuzie

	Clasa Prezisă: Negativ	Clasa Prezisă: Pozitiv
Clasa Reală: Negativ	Adevărat Negativ (TN)	Fals Pozitiv (FP) <i>(eroare de tip I)</i>
Clasa Reală: Pozitiv	Fals Negativ (FN) <i>(eroare de tip II)</i>	Adevărat Pozitiv (TP)

- ▶ Fals pozitiv (FP) – acele cazuri din clasa negativă identificate incorect drept cazuri pozitive.
- ▶ Fals negativ (FN) – cazurile pozitive reale care au fost prezise în mod eronat drept negative.

Măsuri de performanță derivate din matricea de confuzie

- ▶ Acuratețe (Accuracy):

$$(TP+TN)/(TP+TN+FP+FN)$$

- ▶ Precizie (Precision – *positive predicted value*):

$$TP/(TP+FP)$$

- ▶ Sensibilitate (sau Recall – *true positive rate*):

$$TP/(TP+FN)$$

- ▶ Specificitate (Specificity – *false positive rate*):

$$TN/(TN+FP)$$


Măsuri de performanță pentru modelul logistic

- ▶ AUC (Area Under the Curve) reprezintă aria de sub curba ROC (Receiver Operating Characteristic).
- ROC este o curbă care arată relația dintre *True Positive Rate (TPR)* și *False Positive Rate (FPR)* adică între Sensibilitate și Specificitate

Măsuri de performanță pentru modelul logistic – AUC


- ▶ **AUC** indică probabilitatea ca un model să clasifice corect un caz pozitiv și un caz negativ alese la întâmplare.
- ▶ Poate lua valori între 0,5 și 1:
 - $AUC = 0.5$: Modelul are o performanță echivalentă cu o clasificare aleatorie, fără nicio capacitate reală de a distinge între clasele pozitive și negative.
 - $AUC = 1$: Model perfect, clasifică toate observațiile corect.

Măsuri de performanță pentru modelul logistic



ROC curve and the AUC score

Testul Hosmer–Lemeshow

- ▶ Testul Hosmer–Lemeshow este un test statistic folosit pentru a evalua buna potrivire a unui model de regresie logistică (**goodness-of-fit**).
 - ▶ Evaluează cât de bine se potrivesc valorile prezise cu valorile reale ale variabilei dependente binare.
- 

Testul Hosmer–Lemeshow

- ▶ H_0 : Modelul logistic se potrivește bine datelor (nu există diferențe semnificative între valorile observate și prezise).
- ▶ H_1 : Modelul logistic nu se potrivește bine datelor (există diferențe semnificative între valorile observate și prezise).

Testul Hosmer–Lemeshow

▶ *Avantaje:*

- Simplu de interpretat.
- Bun pentru verificarea potrivirii globale a modelului.
- Ușor de implementat în software statistic.

▶ *Dezavantaje:*

- Sensibil la dimensiunea eșantionului

Exemplu

► Datele utilizate:

	A	B	C	D	E	F	G	H
1								
2	salariu	salariu_inceput	ani_educatie	experienta	minoritate	sef	varsta	gen
3	57000	27000	15	144	0	1	43	1
4	40200	18750	16	36	0	0	37	1
5	21450	12000	12	381	0	0	66	0
6	21900	13200	8	190	0	0	48	0
7	45000	21000	15	138	0	0	40	1
8	32100	13500	15	67	0	0	37	1
9	36000	18750	15	114	0	0	39	1
10	21900	9750	12	0	0	0	29	0
11	27900	12750	15	115	0	0	49	0
12	24000	13500	12	244	0	0	49	0
13	30300	16500	16	143	0	0	45	0

Fig 1. Fragment din baza de date

Exemplu

► Variabila dependentă:

◦ *Sef* – variabila binară:

- 0 = angajatul nu detine o functie de conducere,
- 1 = angajatul detine o functie de conducere;

► Posibile variabile explicative:

- Educatie (ani)
- Varsta (ani)
- Gen (0 = feminin, 1 = masculin)
- Minoritate (0 = nu apartine unei minoritati,
1 = angajatul apartine unei minoritati)

Exemplu – estimare coeficienti, odds ratio in SPSS

Variables in the Equation

		B	S.E.	Wald	df	Sig.	Exp(B)
Step 1 ^a	ani_educatie	1.786	.279	41.038	1	.000	5.963
	varsta	.010	.027	.140	1	.709	1.010
	gen	.935	.449	4.335	1	.037	2.547
	minoritate	-2.427	.817	8.815	1	.003	.088
	Constant	-29.646	4.464	44.112	1	.000	.000

a. Variable(s) entered on step 1: ani_educatie, varsta, gen, minoritate.

Exemplu – pseudo-R²

Model Summary

Step	-2 Log likelihood	Cox & Snell R Square	Nagelkerke R Square
1	165.722 ^a	.443	.729

a. Estimation terminated at iteration number 9 because parameter estimates changed by less than .001.

Exemplu – Hosmer–Lemeshow – output SPSS

Hosmer and Lemeshow Test

Step	Chi-square	df	Sig.
1	84.683	8	.000

Exemplu – matricea de confuzie

Classification Table^a

Observed		Predicted		
		sef		Percentage Correct
		0	1	
Step 1	sef 0	380	9	97.7
	1	17	67	79.8
Overall Percentage				94.5

a. The cut value is .500


Acuratețe = 94,5%

Precizie = $TP/(TP+FP) = 67/(67+9) = 88,2\%$

Sensibilitate = $TP/(TP+FN) = 67/(67+17) = 79,8\%$

Specificitate = $TN/(TN+FP) = 380/(380+9) = 97,7\%$

Exemplu – ROC si AUC



Diagonal segments are produced by ties.

$$\text{AUC} = 0,973$$